
YouTube Rising Star 예측

제목으로 채널의 성장 유형을 읽다

호형호제

EPOCH 5th Datathon | 최종 리더보드 0.6145 · 4위




문제 정의와 데이터셋

큰 채널이 아니라, 자기 과거보다 뜰 채널을 찾는다

라벨은 이렇게 만들어진다



각 구간 = 영상별 view_5d(업로드 후 120시간 조회수)의 중앙값 · 학습 라벨은 18일 창



표본 조건: 롱폼만 · past 3편 이상 · past 중앙값 ≥ 100

1,012

게임 채널
7/8-8/31 수집

1,267

학습 행
08-11 601 · 08-25 666

694

예측 행
기준일 09-01

0.20


PR-AUC 무작위 기준
순위만 평가

주요 테이블: videos(제목·설명) · video_5d_views · video_snapshots(1,805만 행) · channel_snapshots · Steam/IGDB

EDA ① 평균 회귀

과거 조회수가 낮았던 채널일수록 Rising이 많다

past 조회수 10분위별 Rising 비율



42%

가장 작은 10%
Rising 비율 (08-25)

1%

가장 큰 10%
Rising 비율 (08-25)


왜? growth가 log 차이라서, 과거가 우연히 낮게 나온 채널이 다음 창에서 반등하기 쉽다

기준선 $B0 = \text{rank}(-\log \text{past})$
 학습 없이 PR-AUC 0.394 (08-25 평가)
 → 모든 모델이 넘어야 할 바닥

EDA ② 데이터 특이사항

모델에 들어가기 전에 확인한 세 가지

업로드일별 view_5d 수준 (채널 평소 대비, log)



1

8/25 이후 롱폼 조회수 급등

test 피처에만 들어가는 구간. 일시적인 수집 현상으로 보고, 조회수 피처는 집계가 끝난 영상만 사용

2

수집 범위가 단계적으로 확장

7/13 업로드 · 7/26 조회수 추적 확장 → 기준일마다 past 관측 기간 32 / 46 / 53일

3

라벨 지속성 33%

08-11 양성 중 08-25에도 양성은 1/3 → Rising은 고정 속성이 아닌 상태. 같은 채널 반복 → 기준일 단위 검증



전처리 원칙

지우지 않고, 미래를 보지 않는다

1

누수 차단

기준일 이전 업로드·스냅샷만 사용. 조회수 피쳐는 120시간 집계가 끝난 영상만

2

결측은 지우지 않는다


행을 지우면 test 316행을 예측할 수 없음 → 중앙값 + 결측 지시변수, "쇼츠 없음" 같은 구조적 결측은 0

3

학습 기준일에만 fit

대치값·스케일러·TF-IDF 어휘까지 하나의 Pipeline으로 묶고 assert로 검증

이상치 처리별 CV PR-AUC (두 기준일 평균)




극단값은 오류가 아니라 "가끔 터지는 채널"이라는 신호 → log 변환만 하고 자르지 않았다

파생변수

남이 아니라 자기 자신과 비교한다

기본 피처 14개에 추가했을 때 Δ PR-AUC



shorts_rel

$\log$ 쇼츠 중앙값 - $\log$ 롱폼 중앙값

쇼츠 시청자에 비해 롱폼이 덜 나온 채널 → 따라 오를 여지

past_shrunk

$(n \cdot \text{채널 평균} + 5 \cdot \text{전체 평균}) / (n + 5)$

편수가 적으면 past는 잡음 → 편수만큼만 믿는다

조기 조회수

최근 5.5일 영상의 48h 조회수 vs 같은 채널 과거 영상


이후 순위 모델에서 gain 1위 (35%)



제목 피처 ① 가장 큰 도약

수치 모델을 다듬으면 +0.03씩, 제목을 넣자 한 번에 +0.067

리더보드 PR-AUC 변화



+0.067

0.4916 → 0.5588

대회 기간 중 최대 단일 도약

처음엔 대안이였다


현호의 401개 설정 비교에서 나온 텍스트 모델. "제목은 수정될 수 있는 정적 정보"라 주력이 아닌 대안으로 분류했다.

제출해 보니 최고점 → 이후 모든 최종 모델이 이 위에 쌓였다



제목 피쳐 ② 만드는 법

채널 하나 = 최근 28일 제목을 이어 붙인 문서 하나



왜 단어가 아니라 문자 n-gram인가

띄어쓰기가 불규칙한 한국어 제목을 형태소 분석 없이 처리하고, 조사·관호가 붙어도 같은 조각을 잡는다

TF-IDF 어휘도 학습 기준일에서만 fit

예: "[메이플 레전드"

[메

[메이

메이

메이플

이플

레

레전

전드


레전드



제목 피쳐 ③ 외운 것이 아니다

두 방향 모두 개선되고, 처음 보는 채널에서 더 크게 올랐다

검증 PR-AUC (같은 로지스틱 구조)



0.373 → 0.429

처음 보는 채널 66개
past 단독 → past + 제목

채널 ID를 외웠다면

학습 때 없던 채널에서는 효과가 없어야 한다. 그런데 오히려 더 크게 올랐다.


→ 제목은 채널이 아니라 "콘텐츠 유형"을 학습했다



제목 피쳐 ④ 무엇을 배웠나

제목은 영상 성과 예측기가 아니라 채널 유형 분류기

제목에 이 조각이 있는 채널의 Rising 비율



같은 단어, 단위를 바꾸면 방향이 뒤집힌다

단어	채널 단위	영상 단위
리뷰	+	+
방송	+	-
레전드	-	+
라이브	-	+

레전드 모음 영상은 그 채널 안에서는 평소보다 잘 나오지만, 그런 영상을 만드는 채널은 덜 성장한다

→ 채널 단위로 묶어야 신호가 된다 (영상 단위 설명력 R^2 1~2%)

전체 양성률 20% 기준 · 리뷰·방송 편집본은 ↑, 레전드 모음·고정 게임·라이브 다시보기는 ↓



제목 피쳐 ⑤ 텍스트를 넓히다

최종 모델의 거의 모든 층에 텍스트가 들어갔다

1 다중 필드 텍스트 (MFT)

제목 + 설명문 앞 300자 + 채널 소개
가중 1 : 0.7 : 0.7

0.561

처음 보는 채널 PR-AUC (T4 0.460)

2 텍스트 확률 → 순위 모델

제목·MFT 확률을 LambdaRank 입력으로
조기 조희수와 결합

15% · 11%

LambdaRank gain 2·3위

3 영상 단위 Attention

제목·설명·태그 문자 TF-IDF → SVD 48
+ 수치, 영상별 가중치 학습

0.6109


E3에 25% 섞어 LB 상승

제목·설명은 수정 이력이 없지만, train·test 모두 같은 시점의 메타데이터라 조건은 동일하다



모델 구성

큰 모델 하나 대신, 서로 다른 신호를 순위로 쌓았다



1 신호를 쌓는다
기준일당 약 600행 → 큰 모델 하나는 금방 외운다
(학습 1.0 vs 검증 0.33)

2 75 : 25 패턴
현재 최고 75% + 새롭고 다른 성분 25% → LB 3연
속 상승 (E3 → E6 → E8)


3 분류보다 순위 학습
같은 수치 22개로 분류 0.392 vs Ranker 0.440. Yeti
Rank(MAP) · depth 4 · L2 15 · 시드 3



성능 평가

검증 설계부터 다시 세우고, LB 0.4567 → 0.6145

검증 방식별 LB 순위 재현력 (LB 있는 6개 구성, 스피어만)



08-11은 test와 분포가 크게 다름 (기준일 구분 AUC 0.91 vs 08-25 0.66) → **정방향 + 부트스트랩으로 판정**

0.6145

최종 LB (E8)

4위 · v07 대비 +0.158

3.1×

무작위 대비

PR-AUC 무작위 기준 0.20

49%

상위 20% 정밀도

정방향 검증 133개 중 65개 적중

검증과 LB가 어긋난 경우도 있었다


E6: 검증 0.498 → 0.472 ↓, LB 0.5956 → 0.6109 ↑ → 판단은 LB 1순위, 정방향 검증 2순위




모델 해석

순위를 움직인 세 신호: 최근 성과 · 콘텐츠 유형 · 평균 회귀

LambdaRank gain 비중



E8 순열 중요도 (섞었을 때 AP 감소)



1 자기 대비 최근 성과
최근 영상의 48h 조회수가 같은 채널 과
거보다 잘 나오는가

2 콘텐츠 유형
리뷰·방송 편집본 ↑, 레전드 모음·고정
게임 ↓


3 평균 회귀 · 규모
작은 채널·편수 적은 채널, 쇼츠 대비 롱
폼 저평가 (shorts_rel)



트랜스포머 ① 무엇을 시도했나

제목을 더 잘 읽으려고 사전학습 언어모델을 붙여봤다

단독 성능 (정방향 PR-AUC)



무작위 기준 0.20 · 같은 정방향 검증(08-11 학습 → 08-25 평가)

모델	방식	결과
BGE-M3	가중치 고정 · 제목 임베딩 → 로지스틱	0.388 · 섞으면 -0.010
KcELECTRA	Colab GPU · 3 epoch 미세조정	0.308 (역방향 0.232) · 섞으면 -0.027
multilingual-e5	제목·설명 임베딩 → PCA + 로지스틱	기존 모델에 섞으면 -0.009
e5 + Attention	영상별 임베딩 → 채널 단위 신경망	단독 0.279

네 가지 모두 단순한 글자 조각 TF-IDF(0.428)를 넘지 못했고, 섞으면 점수가 떨어졌다



트랜스포머 ② 왜 실패했나

모델이 약해서가 아니라, 데이터 크기와 신호의 종류가 맞지 않았다

1 데이터가 너무 작다

600 : 1억

기준일당 채널 약 600개로 약 1억 개 파라미터를 미세조정 → 외우기만 했다. 역방향 0.232 ≈ 무작위

2 필요한 건 의미가 아니라 형식

형식 > 의미

언어모델은 "무슨 게임 이야기인가"로 묶는다. 이 과제의 신호는 "리뷰냐, 레전드 모음이냐". B GE 군집의 양·음 대표 제목이 겹쳤다

3 가벼운 구조는 통했다

LB 0.6109


사전학습 없이 문자 TF-IDF + SVD로 만든 영상 단위 attention은 25% 성분으로 점수를 올렸다

교훈 이 정도 데이터에서는 큰 모델보다 문제에 맞는 표현이 먼저다

아쉬운 점

8/25 이후 조회수 급등을 일시적인 현상으로 보고 넘겼다

채널 규모 5분위별 조회수 급등 크기 (log)



작은 채널일수록 더 크게 뛰었다 (위약 대조를 뺀 값)

본 것

EDA에서 8/25 이후 롱폼 조회수 급등을 특이사항으로 확인 (8/27 이후 약 2배). 쇼츠·좋아요는 그대로



판단

수집상의 일시적인 현상으로 보고, 조회수 피처에서 잘라내거나 정규화하고 넘어감



놓친 것

채널의 84%에서 나타났고 작은 채널일수록 컸다. test의 future 28 일은 통째로 이 구간 → test 라벨에 반영됐을 가능성이 큰 신호를 잡음으로만 다뤘다

교훈 test에만 있는 이상치는 지우기 전에, 예측 기간에도 이어지는지부터 확인해야 한다

정리

01

평균 회귀

작은 채널·편수 적은 채널이 반등한다

02

자기 대비 최근 성과

최근 48시간 성과 vs 자기 평소

03

제목으로 본 콘텐츠 유형

리뷰·방송 편집본 ↑, 레전드 모음 ↓

세 신호를 순위로 쌓아 **0.4567 → 0.6145** · 4위

배운 점: 데이터가 작을수록 큰 모델보다 다양한 약한 신호와 검증 설계가 먼저다

감사합니다 · Q&A