

# YouTube Rising Star Datathon

EPOCH 5th Datathon

---

Team: 최강끼끼

# 문제 정의 · 핵심 발견

- **예측 대상:** 2026-09-01 기준 694개 채널의 Rising(상위 20% 성장) 여부
- **정답 공식:**  $\text{growth} = \log(\text{미래 26일 조회수 중앙값}+1) - \log(\text{과거 조회수 중앙값}+1)$ , 같은 기준일 내 상위 20% = Rising
- **평가지표:** PR-AUC(주), F1(보조). 무작위 기준선은 약 0.20



|                                               |                                                           |                                                         |
|-----------------------------------------------|-----------------------------------------------------------|---------------------------------------------------------|
| <b>① 평균회귀</b><br>과거 조회수가 낮았던 채널일수록 Rising이 많다 | <b>② 8월 말 급등</b><br>08-26 이후 신규 톱품 조회수 약 2.2배 (쇼츠는 변화 없음) | <b>③ 전주 라벨 활용</b><br>08-25 공식 라벨의 정답 구간이 9/1 정답 구간과 겹친다 |
|-----------------------------------------------|-----------------------------------------------------------|---------------------------------------------------------|

# EDA (데이터 이해)

## 데이터 구조 · 타겟 · 결측

### 단위

채널×기준일. 영상 38,411개, 채점대상 694개 채널


### 타겟 분포

growth 상위 20%만 Rising: 양성비율 정확히 20.1%, 불균형 이진분류

### 결측·이상치

영상 38,411개 중 6,887개(17.9%) view\_5d 결측 — 대부분 수집 시작 전 7월 초 업로드 (8월은 3%). 조회수 룬테일 → 로그 변환

## 핵심 인사이트: 과거 중앙값별 Rising 비율



평균회귀: 과거 중앙값 낮을수록 Rising 비율↑  
8월 말 급등: 08-26 이후 조회수 평소 대비 2.2배 급등

# Feature Engineering

04

## 주요 파생변수 · 전처리

### 과거 수준 · 모멘텀

log\_past\_med, mom\_7/14: 정답식(로그 차이) 구조에 그대로 대응

### 변동성


log\_view\_std: 꾸준한 채널과 터지는 채널을 구분

### 전처리


결측→중앙값(로지스틱), HGB는 결측 그대로 처리 · 표준화 ·  
class\_weight=balanced(로지스틱)

## 전주 라벨 활용

09-01 정답 구간의 앞 11일 성과가 이미 반영된 공식 라벨




## 급등 보정(디플레이트) 효과: mom\_7 중앙값



보정 전엔 테스트 피처가 학습 때 본 적 없는 분포(0.53)였고, 디플레이트 후 학습 기준일과 같은 수준(0.00)으로 맞춰졌다

사용 모델: 로지스틱 회귀 + HistGradientBoosting(HGB), 두 확률을 순위로 평균

점수 개선 흐름



선택 이유: 백테스트 PR-AUC (백테스트 1위 ≠ 리더보드 1위)



# 파라미터 튜닝

06

## 주요 하이퍼파라미터

### 로지스틱 회귀

정규화 강도  $C$ ,  $\text{class\_weight}=\text{balanced}$

$C \in \{0.01, 0.1, 1.0\}$ : 차이 없음( $0.381 \cdot 0.381 \cdot 0.379$ )  $\rightarrow 0.1$

### HistGradientBoosting

$\text{max\_depth}=3$ ,  $\text{lr}=0.05$ ,  $\text{max\_iter}=300$ ,  $\text{l2}=1.0$ ,  $\text{min\_samples\_leaf}=30$ , 5시드 평균


튜닝 없이 보수적으로 고정: 과적합을 피하려 얇고 규제가 강한 값 사용

### 라벨 규칙 비중 $w$

모델 점수와 08-25 라벨 규칙을 섞는 비율

급등기 검증 세트(공식 08-25 라벨)로 고르고 리더보드로 교차 확인

## 라벨 규칙 비중 $w$ 별 리더보드 PR-AUC



급등기 검증 세트에서도 0.3~0.5가 최적  $\rightarrow$  리더보드와 일치해 0.5 채택 ( $w = 0$  대비 +0.029)

## 그 외 시도 (피쳐 · 구조)

하이퍼파라미터가 아닌 피쳐 · 모델 구조 실험

구독자 · 채널 총 조회수  
피쳐

이웃 채널(같은 게임) 신호

132h 마스킹 · nowcast 추정

그룹 내 순서 v1 모델 교체


$\rightarrow$  모두 효과가 없거나 점수가 하락해 제외

# 성능 평가

## Validation 방식

날짜 기준 분리(랜덤 분리 금지) + 채널 단위 GroupKFold, 공식 라벨(08-11 · 08-25)로 2차 교차 확인.  
CV 홀드아웃 PR-AUC 0.42~0.44(초기) → 고도화 후 0.56~0.58

## 리더보드 점수 변화 (20회 중 채택 8단계)




# 모델 해석

08

## ① 피쳐 그룹 중요도

그룹을 섞었을 때 PR-AUC 하락폭 · 백테스트 5개 기준일




### 08-25 라벨 >> 과거 수준

그룹 중요도 약 2.7배 차이

## ② SHAP 요약

9/1 테스트 694채널 · HGB 기준



과거 중앙값↑ → Rising↓ (평균회귀)

08-25 기준선↑ → Rising↑ (역추론)


변동성 · 쇼츠↑ → Rising↑

최근 롱폼 수↑ → Rising↓

\* 회색 = 결측

## ③ 개별 예측 사례

08-25 라벨 = 0인데 상위 20%(121위)에 든 채널



164위

라벨 규칙만



83위

모델

라벨이 놓친 채널을 모델이 보완

순위의 절반은 08-25 라벨, 나머지는 평균회귀 · 변동성이 결정

라벨 그룹만으로 순위 변동의 51% 설명 · 상위 139개 중 127개가 라벨 = 1

# 결론 및 인사이트

09

## 0.6707

최종 리더보드 PR-AUC · 베이스라인 대비 +0.215

성능을 결정한 것은 모델이 아니라 데이터 구조

### 가장 중요한 변수 · 패턴

- **전주(08-25) 라벨:** 9/1 정답과 11일 겹치는 공식 라벨 → 최종 순위의 절반을 결정
- **평균회귀:** 과거 중앙값이 낮을수록 Rising (2번째로 중요한 그룹)
- **가끔 크게 터지는 채널:** 조회수 변동성 · 쇼츠 성과가 클수록 Rising
- **급등 보정:** 보정하지 않으면 최근 모멘텀이 가짜 성장 신호 (mom\_7 0.53 → 0.00)

### 인사이트 · 적용 가능성

- **복잡한 모델보다 데이터 구조 파악:** 모델을 바꾸는 것보다 라벨 중첩 · 급등 국면 같은 데이터 구조를 파악하는 것이 성능을 더 크게 좌우
- **급변 시점 감지 후 보정:** 알고리즘 변화처럼 전체 조회수가 바뀌는 시점을 감지해 일괄 보정한 뒤 성장 채널 탐지
- **곧 뜰 채널 조기 발굴:** MCN · 광고주가 평균회귀 · 변동성 신호로 성장 후보를 미리 선별

# 감사합니다

---

Q&A

팀 최강끼끼 · EPOCH 5th Datathon