

EPOCH 5th Datathon · 게임 유튜브 채널 Rising 예측

두 갈래로 본 9월의 Rising

잘린 관측을 학습하고, 보이지 않는 미래를 시뮬레이션하다

Team3 뽀뽀이

박소이 · 박채원



프로젝트 개요

어떤 게임 유튜브 채널이 9월에 "평소보다" 크게 뜰까?

09-01 기준, 각 채널의 향후 26일 롱폼 조회수가 자기 평소보다 얼마나 오를지 순위를 매기는 문제

694

게임 유튜브 채널

26일

09-01 ~ 09-26 미래 창

상위 20%

Rising = 1 · PR-AUC 평가

양성이 20%뿐 → 상위권 순서가 점수를 결정



데이터셋 & 정답 정의

사용 데이터

video_5d_views

영상별 업로드 시각 · 5일 조회수 · 쇼츠 여부

channel_snapshots

날짜별 구독자 수

train_labels

공식 정답 (08-11 · 08-25 두 날짜뿐)

sample_submission

제출 대상 694개 채널 (기준일 09-01)

영상 31,524편 · 07-10 ~ 08-31 (53일)

정답(Rising) 정의

$$s = \log(1 + \text{미래 26일 중앙값}) - \log(1 + \text{과거 중앙값})$$

같은 날 채점 대상끼리 비교해 s 상위 20% → 1

채점 대상: 과거 롱폼 3편 이상 · 중앙값 100 이상


미래 26일 롱폼 0편 → 미래 중앙값 0 → s 크게 낮음

정의를 코드로 구현 → 공식 정답과 98.5% 일치

→ 07-18부터 매일의 학습 라벨 생성



EDA 요약 ① 가장 강한 단서



다음 정답 양성률 (테스트와 같은 26일 창 백테스트)

① 직전 정답이 가장 강한 단서

7일 전 정답이 1이면 다음에도 50%가 1
(0이면 11%, 전체 평균 19%)

② 날짜마다 분포가 크게 이동


08-25~27 플랫폼 전체 조회수 급등
(평소 대비 약 2.2배 → 다음 장)

③ 결측은 무작위가 아님

결측 여부를 다른 피처로 예측하면
AUC 0.73~1.00 → 결측 자체가 정보



EDA 요약 ② 분포가 움직인다



업로드일별 평소 대비 조회수 (08-25~27 급등, 약 2.2배)



상위 20% 문턱: 0.27 (07-18) → 0.60 (08-13)

같은 조회수라도 날짜마다 의미가 다르다 → 절대값 대신 그날의 순위, 최근 날짜에 더 큰 가중



EDA에서 설계로: 세 가지 발견

상대 순위

정답 = 그날 694개 중 상위 20%
정의 역산 → 공식 정답 98.5% 일치



매일 학습 라벨 생성 (07-18~)
피처를 날짜별 순위로

분포 이동

08-25~27 급등 약 2.2배
상위 20% 문턱 0.27 → 0.60



최근일 가중 (반감기 7일)
KFold 대신 시간 기반 검증

잘린 관측

직전 정답 1이면 다음 양성 50%
그런데 08-31 이후가 안 보임



역추론 피처 lag_x_obs
소프트 라벨 · 최종 규칙

그 외: 결측이 무작위가 아님 → 지시변수 + MICE · 채널 약 700개 반복 → 트리 대신 강한 L2 로지스틱

※ EDA와 모델링을 오가며 검증된 패턴만 설계에 반영



데이터 전처리 파이프라인

기준일 D마다, D 이전 데이터만 써서 채널별 한 행 (누수 방지)

01 기본 정리

조회수 log1p 변환
롱폼 · 쇼츠 분리
채점 대상만 학습
(과거 3편 이상,
중앙값 100 이상)



02 파생변수

평소 수준 · 변동성
최근 모멘텀
업로드 패턴
직전 정답 역추론
구조 확률 struct_p



03 날짜별 순위

모든 피처를
그날의 순위로 변환
→ 급등이 와도
기준이 유지됨




04 결측 처리

결측 지시변수 추가
(결측 = 업로드 없음)
MICE로 값 대체
학습 데이터로만 적합
→ 누수 방지

원칙: 정답 규칙(상대 순위 · 중앙값 · 직전 정답)을 그대로 피처로 옮긴다



모델링 ① 우측 중도절단 → 소프트 라벨



예선 LB

0.68



0.76

우측 중도절단(생존분석) 결과가 정해지기 전에 관측이 끝난 데이터 (예: 연구 종료 시 생존 중인 환자)

→ 0으로 두면 편향, 버리면 최신 정보 손실 → 버리지 않고 **확률 q**로 부분 반영

소프트 라벨 관측된 k일로 $q = P(\text{최종 정답 1})$ 추정 → (정답 1, 가중치 q) + (정답 0, 가중치 1-q)

q 모형 정답이 확정된 과거 날짜를 일부러 잘라서 학습 (k/F 입력) = EM의 E-step



모델링 ② 가중 로지스틱 + 시간 기반 검증

왜 강한 L2 로지스틱인가


채널 약 700개가 매일 반복 → 독립 정보 적음
트리(LightGBM)는 노이즈를 외움
→ 시간 검증에서 $-0.03 \sim -0.07$
소프트 라벨 가중치를 그대로 반영

L2 로지스틱이란?

피쳐 가중합 → 시그모이드로 0~1 확률
계수 제곱합에 벌점 → 과적합 방지

시간 기반 검증

데이터가 검증일에 끝난다고 놓고
소프트 라벨까지 다시 만들어 채점 (9일)





모델링 ③ 구조 시뮬레이션 + 랭킹 모델

팀 모델 = $0.8 \cdot \text{구조 시뮬레이션} + 0.2 \cdot \text{T01} \rightarrow \text{단독 LB } 0.7395$



모델링 ③ 모델 발전 과정과 팀 모델 구조

모델 발전 과정 · 팀 최종 블렌드에서의 역할



담당 모델이 최종 제출로 이어지는 구조





모델링 ③-1 성장 점수 랭킹 모델 (T01)

잘린 5일 조회수 복원 · 이진 분류에서 순위 학습으로 · 성능 비교

잘린 5일 조회수 복원

- 수집 시작 전 업로드 **4,110**편의 5일 조회수를 나이별 성장 곡선으로 역산
- 실측 대비 오차 중앙값 **5%** · 검증 0.556 → **0.578**

이진 분류 → 성장 점수 순위 학습

- 1/0 분류는 하위 80% 채널의 순서 정보를 버림
- LightGBM **순위 회귀** · **lambdarank** 4종 + 분류 계열 50 : 50 블렌드


성능 비교

구성	내부 검증	본선 LB
분류 (LightGBM·로지스틱·공식)	0.556	0.6833
분류 2계열 순위 평균	0.578	0.6933
순위 학습 4종 단독	0.586	—
T01 = 순위 학습 + 분류	0.594	0.7032




모델링 ③-2 구조 시뮬레이션

정답이 만들어지는 과정을 그대로 재현 · 급등 처리 · 기준선 대비 성능



학습 없는 기준선 대비 (08-25 운영진 정답)




급등 처리 · 9월 가정 판정

과거 규모 5분위	급등 폭 (log)	가짜 구간 08-13~17
1 (소형)	+1.25	+0.05
3	+0.86	-0.09
5 (대형)	+0.50	-0.08
9월 급등 가정		08-25 정답 로그손실
급등 소멸		0.328
8월 말 폭 그대로 지속		0.275~0.278
폭 0.8배 · 규모 기울기 1.5배 (채택)		0.268



검증 설계: 테스트와 같은 구조로

정보 경계 · 낙관적 폴드와 정직한 폴드 · 급등 국면 검증



본선 구조 검증 (급등 국면 08-28~30, PR-AUC)

모델	평균
지난주 정답 단독	0.588
순위 학습 6종 (특징 82개)	0.647
순위 학습 + 시뮬레이션 특징	0.665
로지스틱 3변수 (시뮬레이션·불일치·규모)	0.698
구조 시뮬레이션 단독	0.713

정직한 폴드가 필요했던 이유

- 학습 정답이 검증일을 넘으면 같은 모델이 **0.594~0.609 → 0.462**
- 정보 경계를 지킨 폴드 + 본선 구조의 급등 국면 검증으로 재비교



추가 분석: 순위 블렌딩 + 중도절단 규칙

순위 블렌딩

1차 팀 모델 0.9 + q_joint 0.1 → 0.7412

최종 팀 모델 0.7 + T01 0.2 + q_joint 0.1 (+ 규칙) → 0.7523

PR-AUC는 순위만 평가 → 각 모델 출력을 순위로 바꿔 결합

중도절단 규칙


08-25 정답 1 + 08-25~31 롱폼 0편인 채널

→ 정답을 만든 영상은 09-01 ~ 09-11에 있음

→ 테스트 창(09-01 ~ 26) 안에 포함

→ **9개 채널을 1~9위로**, 나머지 순서 유지


공식 정답과 08-31 이전 데이터만 사용




다음 정답 양성률 · 테스트와 같은 26일 창 백테스트 (31/40)



최종 제출 코드가 실제로 한 일



① 9개 채널 10~79위 → 1~9위 (나머지 685개 그대로)



② 최종 상위 139개(양성 20% 규모) 중 90%가 08-25 정답 1

왜 이 9개인가 직전 정답 1 + 08-25~31 영상 0편 → 정답을 만든 영상은 9월(테스트 창) → 백테스트 양성률 77.5%

왜 점수가 올랐나 PR-AUC는 상위권 순서로 결정 → 10~79위에 흩어져 있던 고확률 양성을 맨 위로



결과 요약 및 인사이트

0.7115

로지스틱 단독 (q_joint)
생존분석 소프트 라벨



0.7412

팀 블렌드 (+0.030)
+ 구조 시뮬레이션 · T01 순위 결합



0.7523

최종 (+0.011)
+ 비중 7:2:1 · 중도절단 규칙

- ① 잘린 미래를 살린 것이 가장 큰 개선 최근 기준일을 버리지 않고 확률로 학습 → 예선 0.68 → 0.76
 - ② 정답 규칙을 피쳐 · 라벨로 옮기기 날짜별 순위 · 직전 정답 역추론 → 단순한 로지스틱이 트리보다 우세
 - ③ 구조가 다른 모델의 결합 판별(로지스틱) · 생성(시뮬레이션) · 랭킹(T01)이 서로의 오차를 보완
 - ④ 검증 구조를 테스트와 똑같이 다른 후보 규칙은 18일 창 0% → 26일 창 50%로 뒤집혀 기각
- 한계 비중 변경과 규칙을 한 번에 제출해 각각의 기여는 분리하지 못함



향후 계획 및 개선 방향

스태킹

현재

세 모델 순위를 평균

개선

시뮬레이션 확률을
로지스틱 입력 피쳐로
넣어 한 모델에서 학습

비중 최적화

현재

7:2:1은 원칙으로 결정
(주축 + 소량 결합)

개선

26일 창 백테스트로
비중을 탐색해 근거 확보

기여 분리

현재

비중 변경과 규칙을
한 번에 제출

개선

각각 따로 백테스트해
블렌드 · 규칙 기여 정량화

목표: 검증 근거로 설명되는 결합 · 규칙 → 재현 가능한 개선



마무리

잘린 관측은 확률로 학습하고, 보이지 않는 미래는 시뮬레이션으로

두 관점을 순위로 결합하고 중도절단 규칙으로 상위권을 다듬어 최종 PR-AUC **0.7523**

Q & A

감사합니다