


EPOCH 5TH DATATHON

Youtube_rising_star 예측

Team 지5지상

우리가 풀려고 한 문제

01 Track

어떤 Youtube 채널이 앞으로 성장 국면에 들어갈지 어떻게 예측할 수 있을까?

문제 정의

주어진 cutoff 시점에서
향후 Rising 여부를 이진 분류

→ 핵심은
'그 시점에 알 수 있었던
정보'만으로 예측하는 것

처음의 가설


Feature Engineering이
가장 중요할 것이라고 판단

→ 전처리 후 파생변수 생성에 집중
→ Random Forest를 유지하며 반복

결과

PR-AUC가 0.4~0.5에 정체

→ 'Feature만의 문제인가?'
→ 모델 구조를 바꾸기로 전환



데이터와 평가 기준

02 Track

원천 데이터 4종에서 1,258개의 cutoff(특정시점 정보)-label(실제 성장 여부)을 구성

사용 데이터

train_labels

- target / row_id

channel_snapshots

- subscriber_count / total_view_count / video_count

videos

- published_at / is_shorts / duration_sec

video_5d_views

- view_5d / like_5d / comment_5d

1,258

labels



양성 20.1%

음성 79.9%

08/11

596

TRAIN

08/25

662

Validation

평가 1순위 : PR-AUC

왜 PR-AUC인가?

03 Track

양성 클래스가 약 20%인 불균형 분류 문제

Accuracy가 아닌 '양성을 얼마나 잘 찾아내는가'에 초점

Accuracy

음성만 많이 맞혀도 높아질 수 있음

PR-AUC

Positive를 얼마나 잘 상위에 배치하는지 평가

ROC-AUC

보조 지표로 사용
PR-AUC 동률 해소

253 / 1,258

양성 20.1%

전처리와 결측치 처리

04 Track

모델별 pipeline 내부에서 결측치를 처리해 fold 밖의 정보를 사용하지 않도록 설계

결측치

median imputation
+ missing indicator

→ 값 자체와 '결측 여부'를 함께 전달

불균형

LightGBM / XGBoost
→ scale_pos_weight
ExtraTrees → balanced class weight
HistGB → balanced sample weight

Pipeline

각 CV fold에서
imputer를 다시 fit

→ validation fold의 통계량이
학습에 섞이지 않게 함

전처리의 목적

성능을 '올리는 것'보다 먼저, 성능이 누수로 부풀려지지 않게 만드는 것

Feature Engineering: '크기'보다 '변화'를 표현

05 Track

581개 feature를 총 4가지 방향으로 설계

① 최근 성장

-subscriber / view
-7·14·28일 delta·growth·daily delta

② 성장 가속도

-성장률 가속도(최근 7일 slope - 이전 7일 slope)

③ 업로드 패턴

-uploads · shorts fraction
-last_upload_age · frequency ratio

④ 업로드 후 5일간 성과

-view / like / comment
-rate · momentum · short/long ratio

시간창

0-7일

7-14일

14-28일

28-56일

최근 ↔ 이전 구간의 차이로 momentum을 표현

'581개 feature'가 의미하는 것

06 Track

feature 개수보다 중요한 것은 어떤 정보를 반복해서 표현했는가




→ 같은 원천 신호를
여러 시간창.통계량으로 표현

성능 정체 이후: 모델을 바꾸다

07 Track

Random Forest에 feature를 계속 추가하던 접근에서 4개 모델군 비교로 전환



중요한 변화: 'feature만 바꾸기' → '모델 구조 다양화하기'

앙상블 : 서로 다른 모델 결합

08 Track

단순히 한 모델만 고르는 대신 여러 결합 전략으로

Weighted Soft Voting

예측 확률의 가중 평균

Rank Averaging

확률이 아닌 순위를 평균

OOF Tuned Blend

훈련 OOF에서 weight를 탐색

OOF Stacking

OOF prediction을 meta-model에 입력

핵심

앙상블은 '무조건 성능 향상'이 아니라, 서로 다른 오류를 보완할 때 효과적

Hyperparameter Tuning과 OOF

09 Track

모델별 후보를 Random Search로 탐색하고, 5-fold OOF prediction을 생성

ParameterSampler 기반 탐색

LightGBM

- trees 200–700 · lr 0.015–0.09
- depth 3–7 · leaves 7–47

XGBoost

- trees 200–700 · lr 0.015–0.09
- depth 2–6 · min_child_weight 1–25

ExtraTrees / HistGB도 별도 탐색

5-Fold Stratified CV



각 fold의 hold-out prediction

OOF prediction → ensemble 입력

5-Fold Stratified CV로 안정적인 모델 비교 → 8/25 최신 cutoff를 별도 Hold-out으로 확인

검증 전략과 한계

10 Track

08/25를 최신 cutoff hold-out으로 분리했지만, 아직 시간축 검증은 충분하지 않다

08/11 · 596개 · TRAIN

08/25 · 662개 · HOLD-OUT

과거

미래

검증 전략

08/25 최신 데이터를 별도로 분리해,
학습 데이터와 다른 시점에서 성능을 확인

한계

08/11 → 08/25, 두 개의 cutoff만 사용
→ 여러 시점에서 성능을 확인하기에는 한계가 있음

다음 단계: cutoff를 여러 시점으로 늘려 rolling / time-based validation

최종 결과: Public Leaderboard

11 Track

0.5192

Public LB · PR-AUC

무엇을 확인했나

평가·제출 모두
PR-AUC 중심으로 정렬

어떤 신호를 강조했나

절대 채널 규모보다
growth · acceleration · momentum
중심

핵심 인사이트

좋은 Feature를 만드는 것과
그 Feature를 어떻게 학습시키는가는
별개의 문제

최종 성능은 특정 모델 하나보다, 데이터 설계부터 모델 앙상블까지의 전체 과정이 만들어낸 결과

왜 성능이 더 높아지지 않았을까?

12 Track

이번 프로젝트의 결과를 '모델 성능'만이 아니라 '정보의 한계' 관점에서 다시 봄

① 정보의 다양성

581개 feature지만
원천 데이터는 4종

=> 새로운 정보보다 기존 성장·반응
정보를 다양한 방식으로 변형

② 시간 검증

08/11 → 08/25
한 번의 시간 이동만 검증

=> 다른 기간에서도 같은 성능인지
확인하기 어려움

③ Feature 중복 가능성

delta / growth / daily delta
mean / median / p75 등

=> feature 수가 늘어도
독립 정보가 늘어난 것은 아님

따라서 'feature를 더 많이'보다

새로운 정보 + 더 강한 시간축 검증 + feature selection

향후 개선 방향

13 Track

현재 구조에서 가장 우선순위가 높은 개선

01

Cutoff 확대

여러 시점의 데이터를 활용해 시간 흐름에 따른 성능을 검증

02

정보 다양화

허용되는 추가 메타데이터가 있다면 새로운 종류의 변수 확보

03

Feature Selection

581개를 무조건 늘리기보다 중복·불필요 feature를 줄이고 안정성 확인

04

**Rank / Calibration
재검증**

앙상블 방식이 실제 외부 평가에서도 안정적인지 확인

현재 Public LB

0.5192

PR-AUC

→ 단순 성능 향상보다
다양한 시점에서도 안정적으로 검증할 수 있는 방법 마련

결론

Feature Engineering → Model Diversity → Ensemble

다음 설계 방향

1)데이터 재분석 2)Feature 재설계 3)시간 검증 강화

필요한 신호를 선별하고 실제 성장 흐름에 맞게 다시 설계

Q & A
