

Youtube Rising Star Datathon

건호 · 현호

EDA (데이터 이해)

작은 채널일수록 오른다 — **평균 회귀**



1,267

학습 행 · 기준일 2 개




20%

Rising = 성장 상위




×2

8/27 이후 롱폼 조회수



채널 규모별 조회수 부풀림 K (log)



FEATURE ENGINEERING

누수 없이 , 자기 채널과 비교



누수 차단

관측 완료 영상만 (strict)



상대 성과

같은 나이 , 자기 과거 대비



조기 조회수

최근 48h · 부풀림 보정




채널 텍스트

제목 · 설명문 TF-IDF

전처리 : fold 내부 fit · 중앙값 + 결측 지시변수 · arcsinh · 클리핑 없음

파생변수 추가 효과 (PR-AUC Δ)



모델 설계

서로 다른 신호를 쌓는 **순위 앙상블**



기준선 B0 = 과거 조회수 순위

단독 AP 0.394



단일 모델은 과적합

→ 순위 · 점수 평균으로 혼합




6 개 모델 결합

LR · RF · LambdaRank · LGBM · Attention · Ranker

리더보드 PR-AUC


0.4567 → 0.6145

v07 대비 +0.158



파라미터 튜닝

분류보다 순위 학습이 강했다




같은 수치 22 개 · 모델별 단독 정방향 AP




성능 평가

검증 · 리더보드 모두 상승



리더보드 PR-AUC 추이



ΔAP 95% 구간 [-0.003, +0.028] · 같은 검증셋 반복 사용 · 역방향 AP 하락

모델 해석

무엇이 순위를 움직였나

제목 키워드 (양성률)




→ 채널 콘텐츠 형식 신호


처음 보는 채널에서도
AP 0.373 → 0.429

permutation = 고정 E6 위 조건부 민감도
(인과 효과 · SHAP 아님)

LambdaRank gain



E8 수치 성분 permutation (혼합 AP 감소)



결론 및 인사이트

결론 : 다양한 신호의 순위 혼합

패턴



평균 회귀 + 최근 상대 성과 + 콘텐츠 형식

방법



단일 모델보다 서로 다른 신호의 순위 혼합

교훈



피처 수보다 목적함수 : 분류 0.392 → 순위 0.440

0.6145

최종 리더보드 PR-AUC
무작위 0.20 의 3.1 배



적용

성장 후보 채널 스크리닝
상위 20% 중 49% 적용



한계

기준일 2 개 · 검증- LB 불일치
제목 수정 이력 없음