



Youtube Rising Star Datathon

Team 최강끼끼

EDA (데이터 이해)

1,012

게임 채널

38,411


영상

694

채점 채널 · 상위 20%


Rising = 기준일 내 상위 20%의 $\ln(\text{미래 중앙값}) - \ln(\text{과거 중앙값})$

과거 성적이 낮을수록 Rising ↑ (과거 중앙값 5분위)



08-26 이후 업로드분만 조회수 급등 (채널 평소 대비 log)

×2.2 8/26 이후 업로드분만



평균 회귀 + 테스트에만 있는 급등 국면

FEATURE ENGINEERING

1

채널 이력 23개

과거 수준 · 모멘텀 · 변동성 · 업로드 빈도

2

전주(08-25) 라벨 활용 8개

정답 구간이 9/1 정답 앞 12일과 겹침

3

라벨 제약 11개

라벨=1이면 높은 영상이 몇 개 필요했나

4

급등 디스플레이트

업로드일별 상승분 제거

5

학습 데이터 재현

기준일 07-26~08-05 × 같은 구조

5,102행

디스플레이트 효과 — 최근 모멘텀(mom_7) 중앙값



성장은 크기가 아닌 변화 — 기준선과 국면을 맞춘다

모델 설계

s4

디스플레이트

s3

라벨 제약 + 기준선 보정

s15

급등 보정판

양상블

순위 평균
0.35 · 0.35 · 0.30

08-25 라벨 규칙


라벨 1 → 없음 → 0
동점은 과거 중앙값 낮은 순

최종


50 : 50
순위 블렌드

각 모델 = HGB(깊이 3, 5시드) + 로지스틱(C=0.1) 순위 평균

백테스트 PR-AUC — 복잡할수록 LB 하락



리더보드 개선 흐름



복잡한 모델보다 올바른 정보원을 찾는 것이 성능을 좌우했다




파라미터 튜닝

HGB depth 3 · lr 0.05 · 300회

LR C 0.1 · balanced

5시드 평균

08-25 라벨 규칙 비중 → 리더보드



0.3 → 0.5는 +0.001로 수렴 → 50% 채택


성능 평가

시간 분리
평가일보다
4일 이상 앞선 학습

채널 GroupKFold
같은 채널
섞임 방지

급등 국면 검증
08-25 라벨을
정답으로 재현


백테스트 vs 리더보드 — 같은 방향으로 상승




CatBoost: 백테스트 +0.04 → LB -0.04 · 복잡도는 백테스트가 과대평가

모델 해석

Feature importance (HGB permutation) ■ 전주 라벨 피쳐



08-25 라벨별 실제 Rising 비율



결론 및 인사이트

① 08-25 라벨

9/1 정답 구간과 12일
겹치는 거의 유일한 직접
신호

50% vs 11%

라벨 1 / 0 채널의 실제 Rising 비율

② 평균 회귀

로그 차이 정답 → 과거가
낮은 채널이 오르기 쉬움

31% → 10%

과거 중앙값 하위 → 상위 20%

③ 국면 보정

모델 종류보다 학습·테스트
국면 차이 보정이 성능을
결정

× 2.2

테스트에만 있던 급등을
디플레이트

0.6707

최종 리더보드 PR-AUC

+0.215

베이스라인 0.4554 대비

적용 전체 조회수 급변 시점 감지 → 디플레이트 후 “곧 뜰 채널” 조기 발굴 · **한계** 08-25 라벨(09-01 이후 성과 반영) 사용 — 운영진 확인 필요