

Youtube Rising Star Datathon

Team 뽀뽀이

EDA (데이터 이해)

데이터 구조

- 게임 유튜브 채널 **694** 개 , 07-10 ~ 08-31 수집
- 핵심 : 영상별 업로드 **5** 일 조회수 (**view_5d**), 롱폼 / 쇼츠 구분 + 구독자 스냅샷

타겟 정의 · 불균형

- $s = \log(\text{미래 26 일 롱폼 중앙값}) - \log(\text{과거 중앙값})$
- 기준일별 s 상위 **20%** = **1** → 양성 20% 불균형 → **PR-AUC**
- 정답 규칙을 역산해 공식 08-11 라벨과 **98.5%** 일치 재구성 → 매일 학습 라벨 생성

결측 · 이상치

- 결측 여부가 다른 변수로 예측됨 (AUC 0.82~1.00) → **MCAR** 아님 , " 최근 업로드 없음 " 같은 구조적 결측

핵심 인사이트

- **08-25~27** 플랫폼 전체 조회수 급등 → 미래 창 전체가 영향
- 지난주 정답 (**prev label**) 이 최강 단서 : 다음 양성률 50% vs 11%

" 평소 대비 상대 순위를 맞추는 문제 "

FEATURE ENGINEERING

기본 파생변수 (D 이전 데이터만)

- 수준 · 변동 : past_med, past_std, cv_last10
- 모멘텀 : m3, m7, last3_m, r14_med, slope
- 업로드 : upl_rate, days_since, 쇼츠 비중 , 구독자

지난주 정답 역추론 (가설 기반)

- **lag_x_obs** = 정답 1 인데 이미 관측된 앞부분 (08-25~31) 이 약함 → 9 월 초 영상이 강했다
- **no_lag_x_obs** = 정답 0 인데 앞부분이 강함 → 뒷부분이 약했다

정답 규칙을 직접 반영

- **hr10**: 최근 10 편 중 과거 중앙값을 넘긴 비율 (중앙값 규칙의 적중률)
- **struct_p** = $\sum \text{Pois}(n) \cdot P(\text{Binom}(n,p) \geq n/2)$: 미래 n 편 중 과반이 문턱을 넘을 확률

전처리

- 날짜별 백분위 순위 변환 (라벨이 상대 기준이라)
- 결측 지시변수 5 개 + **MICE** 대체 , 표준화

" 가장 중요한 파트 : 라벨 규칙을 피쳐로 옮기기 "

모델 설계

① 로지스틱 회귀 (q_joint)

- 강한 L2 + 최근일 가중 (반감기 7 일)
- 선택 이유 : 채널 ~700 개 반복이라 독립 정보 적음 , 라벨 노이즈 큼 → 트리 모델 (LightGBM) 은 -0.03~-0.07

② 생존분석 : 우측 중도절단 소프트 라벨

- 데이터 끝 (08-31) 에서 미래 창이 잘린 기준일을 버리지 않고 $q = P(\text{최종 1} | \text{앞 } k \text{ 일 관측})$ 추정
- ($y=1$, 가중 q) + ($y=0$, 가중 $1-q$) 로 학습 = EM 의 E-step
- 예선 **0.68** → **0.76** 의 핵심

③ 구조 시뮬레이션 (팀원)

- 칼만 필터로 채널 수준 추정 → 업로드 수 · 조회수 몬테카를로 → 정답 산식 그대로 확률 계산
- 08-25 급등 폭 추정 + 지난주 정답으로 조건부 가중

단계	LB PR-AUC
로지스틱 + 소프트 라벨 (출발)	0.7057
+ 구간 · 구조모형 순위 블렌드	0.7075
+ lag1feat (관측 질 피쳐)	0.7090
+ lag1q + q_joint (q 모형 통합)	0.7115
구조 시뮬레이션 계열 (팀원)	0.7395
blend_90: 0.9·sim 계열 + 0.1·q_joint	0.7412
최종 : 블렌드 + 지난주 정답 규칙	0.7523

최종 제출 (LB 0.7523)

- $0.7 \cdot \text{rank}(\text{mate}) + 0.2 \cdot \text{rank}(T01) + 0.1 \cdot \text{rank}(q_joint)$ 순위 블렌딩
- **지난주 정답 1 + 08-25~31 롱폼 0 편** 채널 9 개를 최상위로 (26 일 창 백테스트 양성률 77.5%)

파라미터 튜닝

튜닝 대상

- 규제 강도 C: 0.015 / 0.1 (모델별)
- 최근일 가중 반감기 : 3·5·**7**·10·20 일
- 블렌드 비중 : 0.4 / **0.5** / 0.6, 최종 90:10
- 소프트 라벨 옵션 : q_x, soft_k, q_joint

튜닝 방법

- 옵션마다 플래그 단위 **A/B**, 시간 검증 9 일 평균 AP 비교
- 채택 기준 : 평균 상승 + 대부분의 날 개선 + 큰 하락 없음

성능 변화 (검증 AP)

- 기본 0.555 → 소프트 0.561 → 구조 0.570
- +lag1q·q_joint 0.574 → **+hr10 0.578**

" 깊이보다 논리 : 채택 / 기각 근거를 남긴다 "

성능 평가

Validation: 시간 기반 (KFold 금지)

- 같은 채널 반복 + 미래 창 겹침 → KFold 는 **0.65** 로 부풀림 (정직한 값 0.40~0.57)
- "데이터가 검증일에 끝난다" 고 놓고 소프트 라벨 ·q 모형까지 전부 재생성
- 검증 +0.009 ≈ LB +0.002 로 축소 반영


설정	검증 AP	LB
로지스틱 + 소프트 라벨	0.561	0.7057
+ lag1feat	0.571	0.7090
+ lag1q + q_joint	0.574	0.7115
blend_90	—	0.7412
최종 (+ 규칙)	—	0.7523

모델 해석

SHAP (로지스틱 → 선형 SHAP = 계수 × 편차)

- lag(+), lag_x_obs(+)**: 지난주 정답 1, 특히 관측 앞부분이 약했던 채널 → 9 월 초 강세
- rk_past_med(-)**: 이미 평소 조회수가 큰 채널은 덜 오름 (평균 회귀)
- rk_struct_p(+)**: 업로드 많고 변동 큰 채널 → 중앙값이 문턱을 넘기 쉬움
- nolag_x_obs(-)**: 정답 0 인데 초반만 강했던 채널은 하락

" 왜 그렇게 예측했는가 : 정답 규칙의 구조가 그대로 드러남 "



결론 및 인사이트

가장 중요한 변수 / 패턴

- 지난주 정답 + 이미 관측된 앞부분의 역추론 . 최종 상위 139 개 중 **88%** 가 지난주 정답 **1** → 승부는 이 그룹 내부의 순서

모델로부터 얻은 인사이트

- 라벨 규칙 (중앙값 · 상위 20% · 잘린 창) 을 피쳐와 생존분석 소프트 라벨로 직접 옮길 때 가장 크게 개선 , 모델 복잡도는 효과 없음
- 검증 구조가 테스트와 다르면 결론이 뒤집힘 : "초반 강세 + 정답 0" 채널 양성률이 18 일 창에서는 0%, 테스트와 같은 26 일 창에서는 50% → 테스트 구조 그대로 백테스트 후에만 채택

실제 적용 가능성

- MCN · 광고주의 급등 채널 사전 선별 , 크리에이터의 업로드 전략 (빈도 · 연속 적중) 모니터링