

YouTube Rising Star Datathon

Public LB 0.5192


EDA (데이터 이해)

train_labels · channel_snapshots · videos · video_5d_views 사용

라벨 1,258 개 , cutoff 2 개 (08/11 · 08/25)

학습 596 / 검증 662, 최신 cutoff 를 hold-out 으로 사용



양성 253 개 (20.1%) 의 불균형 이진 분류 → PR-AUC 중심 평가



Point-in-time 원칙 : 각 cutoff 이전 정보만 사용하며 , video_5d_views 는 available_at < cutoff 인 관측치만 반영

FEATURE ENGINEERING

1·3·5·7·14·21·28·56 일 delta / growth / daily delta
업로드 빈도 · shorts 비율 · 영상 길이 · last_upload_age
5 일 view / like / comment 통계와 rate, momentum, short↔long 비율



결측치는 Pipeline 내부 median imputation + missing indicator 로 처리

모델 설계


후보 모델 : LightGBM · XGBoost · ExtraTrees · HistGradientBoosting

이전 cutoff 학습 파트에서 5-fold Stratified CV 로 모델별 후보 선택

검증 단계에서 soft voting · rank averaging · OOF tuned blend · stacking 비교

최종 선택 기준 : average_precision_score(PR-AUC), ROC-AUC 는 tie-break

불균형은 scale_pos_weight / balanced weighting 으로 보정



모델 이름 자체보다 시간 누수 방지 + 최근 변화량 / 모멘텀 feature 가 성능을 좌우하도록 설계

파라미터 튜닝

ParameterSampler 기반 random search + anchor 설정

LightGBM

trees 200-700 · lr 0.015-0.09 · depth 3-7
num_leaves 7-47 · subsample/colsample · λ 1-60

XGBoost

trees 200-700 · lr 0.015-0.09 · depth 2-6
min_child_weight 1-25 · subsample/colsample · λ 1-60

ExtraTrees

500 trees · min_leaf 1-20 · depth
None/5/8/12/18/24
max_features 0.3-1.0

HistGB

iter 150-500 · lr 0.015-0.09 · leaf 7-31
min_leaf 12-60 · L2 0.5-60

불균형 보정 : scale_pos_weight / balanced sample weight

성능 평가

0.5192

Public Leaderboard · PR-AUC

검증 설계

08/11 596 개

08/25 662 개

train cutoff → latest cutoff hold-out

inner: 5-fold StratifiedKFold 로 평균 AP 비교

outer: 최신 cutoff 에서 validation winner 선택

PR-AUC 가 1 순위 , ROC-AUC 는 동물 해소용

반복 채널 · 인접 시점으로 inner CV 가 낙관적일 수 있어 hold-out 을 별도로 유지

08/11 양성 20.1%

08/25 양성 20.1%

모델 해석

최종 코드에는 SHAP 값을 저장하지 않았으므로 임의 중요도 대신 , 실제로 모델에 투입한 신호 구조를 해석했습니다 .

① 최근 성장
subscriber / view
7·14·28 일 growth

② 성장 가속도
최근 7 일 vs 이전 7 일
daily slope 차이

③ 업로드 패턴
uploads · last_upload_age
frequency ratio

④ 5 일 반응
view_5d · like/comment rate
short ↔ long 성과

시간창 설계

0-7 일

7-14 일

14-28 일

28-56 일

최근 ↔ 이전 구간 차이로 momentum 생성

결론 및 인사이트

시점 누수 방지
cutoff 이전 관측치만 사용
5 일 성과는 available_at 조건 적용

성장 “속도” 중심
절대 채널 규모보다 growth · acceleration
· momentum 을 강조

평가와 제출 일치
PR-AUC 를 모델 선택의 1 순위로 사용
Public LB 0.5192 기록

향후 개선 : cutoff 수 확대를 통한 시계열 검증 강화 · 승인된 외부 메타데이터 결합 · rank/calibration 전략 재검증