

Youtube Rising Star Datathon

팀 오감자

EDA (데이터 이해)


데이터 구조 채널 694개(9/1 표본) · 롱폼 view_5d 21,859편 · 영상 스냅샷 1,805만 행 · 공식 라벨은 기준일 2개(8/11, 8/25).

타겟 성장 = $\log(\text{미래 롱폼 view_5d 중앙값}) - \log(\text{과거 중앙값})$, 기준일별 상위 20%가 1. 양성 20%의 불균형이고 지표는 PR-AUC. "자기 평소 대비" 오른 채널이 정답.

결측·이상 배포 view_5d 표는 120시간 보간값, 라벨은 108~132시간 구간 최댓값. 배포 표에 없는 영상 282편. 스냅샷으로 다시 계산하면 공식 표본 694/694 재현(배포 표 688).

핵심 인사이트 ① 8/27부터 롱폼 조회수가 전 채널에서 약 2배(+0.7 log). 좋아요·쇼츠는 그대로 → 집계 기준 변경.


업로드일별 view_5d — 채널 자기 평소 대비 (log 차이, 중앙값)



핵심 인사이트 ② 8/25 라벨의 미래 18일 중 11일(9/1~9/11)이 테스트 구간과 겹침.

Feature Engineering

① 숨은 구간 역산 8/25 라벨이 Rising인데 보이는 7일이 약했다면 숨은 11일이 강했다는 뜻 → 점수 올림(반대는 내림).



$$B1 = \text{rank}(E) + 0.5 \times \text{라벨} - 0.25 \times \text{rank}(\text{보이는 성장})$$

② 채널별 급등 크기 8/27~31 영상의 (log 조회수 - 평소 수준) 평균. 영상이 적을수록 예상값 쪽으로 수축(경험적 베이스).


③ 기존 영상 배율 8/22 이전 영상의 일 조회 증가율을 급등 전후로 비교(같은 영상의 이중차분, 나이 효과 제거). 급등 영상이 0~1편인 302채널 중 288개에서 계산 → 급등 크기 예측 OOF R^2 0.211 → 0.285.

④ view_5d 재계산 코드북 정의대로 스냅샷에서 다시 계산해 과거 중앙값을 정답과 같은 값으로 맞춤.

⑤ E의 입력 28개 평소 수준, 최근 7·14일 흐름, 업로드 활동, 반응 비율, 초반 24·48시간 조회수.

전처리 모든 입력을 기준일 안 순위로 정규화(정답이 "그날 상위 20%"이므로) · $\log_{1p}$ · 최근 기준일 가중 $\times 0.7$.

모델 설계



사용 모델

방법 ① B1 = LightGBM 분류(E) + 8/25 라벨 + 숨은 구간 보정.

방법 ② 구조 시뮬레이터 = 정답 규칙대로 9/1~9/26 영상을 16,000×4회 생성하고, 8/25 라벨이 공식 정답과 같게 나온 세계만 남겨 P(9/1 Rising)을 집계.

선택 이유

급등은 학습 구간에 없던 변화라 학습 모델은 볼 수 없음(E의 8/25 hold-out AP 0.29).

라벨 정의를 그대로 계산하는 시뮬레이터는 "급등 영상이 과거에 들어가 기준이 올라가는 효과"까지 반영. 두 방법은 순위상관 0.65로 틀리는 채널이 달라 순위를 반반 평균.

baseline → 개선 흐름

연습: 규칙 0.37 → LGBM 0.57 → 8/25 라벨·보정 0.72

본산: B1 0.6913 → 시뮬레이터 결합 0.7369 → 급등 사전분포 0.7381 → 기존 영상 배율 0.7437 → 신뢰도 0.6 0.7449 → view_5d 재계산 **0.7466**

파라미터 튜닝

설정	값	정한 방법
E (LightGBM)	트리 300, 학습률 0.03, 잎 15, 시드 5 평균	고정(탐색 없음)
B1 가중	라벨 0.5, 보정 0.25	8월 기준일 13개 검증(12개 상승)
급등 지속성	0.5~0.75 평균	8/25 라벨 우도(0.4~0.6 최대)
잡음	채널 0.3, 영상 ×1.3	고정. 0.5·t분포로 바뀌도 차이 없음
사전분포 신뢰도	0.6	LB: 0.28 → 0.7437, 0.6 → 0.7449, 0.8 → 0.7408
결합 비중	0.5	LB: 0.35·0.5·0.65 → 0.7375·0.7381·0.7369

방법 694행에서는 ±0.03이 잡음이라 grid·optuna 탐색은 하지 않았습니다. 설정마다 "무슨 근거로 골랐는지"를 남겼습니다.

성능 변화 결합 가중·척도만 바꾼 후보 6개는 모두 B8 대비 -0.0003~-0.0019. 가중 조정으로는 오르지 않았고, 오른 것은 급등 크기 추정을 고친 변경뿐입니다.

밝혀 둘 점 신뢰도 0.6과 결합 비중 0.5는 LB로 고른 값입니다. 채널별 정답을 LB로 역산하지는 않았습니다.

성능 평가


Validation 9/1 정답이 없어 K-fold 대신 간접 검증 세 가지.

① 8/25 공식 라벨을 가리고 맞추기(시뮬레이터): AP 0.77 → 0.81 → **0.820**

② 급등 전 기준일(같은 결합 구조): 8/07 결합 0.62(E 0.53, 시물 0.59) · 8/11 결합 0.59(E 0.47, 시물 0.53)

③ 라벨 재현: 공식 표본 100%, 8/11 라벨 불일치 3/601

본선 Leaderboard (PR-AUC, 무작위 기준 0.20)



진짜 잘 된 건지 가장 큰 상승(결합 +0.046)은 급등 전 검증에서도 재현됩니다. B26 이후의 차이(+0.003)는 잡음 범위 안이고, 로컬 지표는 LB 순서를 두 번 틀렸습니다(신뢰도 0.8, B32 0.7242).

모델 해석

무엇이 점수를 만들었나 (하나씩 빼거나 더한 제출)

8/25 라벨을 학습에서 제외	0.5641 → 0.3186 (연습)
숨은 구간 보정항 제거	0.6913 → 0.6616
시뮬레이터와 순위 평균	0.6913 → 0.7369
급등 크기 추정 개선 + view_5d 재계산	0.7369 → 0.7466

B31 상위 139개 중 121개가 8/25 Rising. 시뮬레이터 평균 확률은 8/25 Rising 채널 0.60, 아닌 채널 0.10.

SHAP 대신: 시뮬레이터는 채널별 수치 5개(평소 수준, 변동 폭, 업로드율, 급등 크기, 과거 중앙값)로만 계산해 채널마다 이유를 직접 읽을 수 있습니다.

왜 그렇게 예측했는가 (채널 ID는 규칙상 적지 않음)

	채널 B	채널 C	채널 D
8/25 라벨	Rising	아님	Rising
급등 크기	약 21배	약 3배	—
과거 중앙값	320 → 2,540	1,870 → 1,910	6,786 → 2,086
방법 ① / ②	상위 7% / 0.005	상위 31% / 0.54	② 0.22 → 0.56
최종 등수	344위	135위	114.5 → 70.5위

B: 급등 영상이 9/1 기준에서는 "과거"에 들어가 기준이 8배로 오름. C: 영상 47편이라 과거가 거의 안 움직이고 9월은 전부 급등 후. D: 배포 표에 빠진 영상 2편을 넣자 과거 중앙값이 1/3로 내려감.

결론 및 인사이트

가장 중요한 변수·패턴

- ① 직전 라벨: 테스트 구간과 겹치는 11일의 정보.
- ② 채널별 급등 크기: 집계 기준 변경으로 오른 정도가 채널마다 다르고(하위 25% +0.34, 상위 25% +1.2 log), 9월 성장을 좌우.
- ③ 과거 중앙값의 정확한 계산: 급등 영상이 과거에 들어가면 기준 자체가 오름.

얻은 인사이트 · 적용 가능성

학습 구간에 없던 구조 변화는 블랙박스 모델만으로 잡히지 않습니다. 라벨 정의를 그대로 시뮬레이션하면 대응할 수 있습니다.

"자기 대비 성장" 지표는 플랫폼의 집계 기준 변경에 크게 흔들립니다. 실제 서비스에서 Rising 채널을 뽑을 때는 채널별 배율 보정이 필요합니다.

배포 표를 믿기 전에 라벨을 직접 재현해 보는 것이 가장 값진 점검이었습니다.

한계와 밝혀 둘 점

- 8/27~31 업로드 영상의 view_5d(9/1 이후 관측)와 8/25 공식 라벨을 씁니다(운영진 답변: 사용 가능).
- view_5d는 8/31까지의 스냅샷으로 다시 계산했습니다. 외부 데이터는 최종 모델에 쓰지 않았습니다.
- 9/12~9/26은 어떤 라벨도 보지 못해 "급등 유지" 가정에 의존합니다.
- 694행이라 ±0.03은 잡음입니다. B4 이후의 개선(+0.0097)은 통계적으로 확인된 것이 아닙니다.